Eksploracja danych
Projekt

Marcin Fabrykowski

3 lipca 2013

Spis treści

1 Opis problemu

Celem projektu jest opracowanie klasyfikatora drzewiastego do klasyfikacji wina na podstawie jego parametrów.
Jako zbiór do nauki, został wykorzystany zbiór
http://archive.ics.uci.edu/ml/datasets/Wine+Quality

2 Opis etapu przygotowania danych

Dane źródłowe zamieszczone na stronie internetowej były zapisane w formacie CVS (załączony plik winequality-white.csv_orig).
Plik wejściowy musiał zostać przekonwertowany na format możliwy do wczytania przez bibliotekę Orange.
Należało zastąpić separator ';' tabulatorem separującym, oraz usunąć cudzysłowia z z nagłówkowego wiersza.
Efekt konwersji jest widoczny w pliku: winequality-white.csv

3 Klasyfikator

Klasyfikator jest operatorem potrafiącym, po wcześniejszym 'nauczeniu', przewidzieć klasyfikowaną wartość na podstawie badanych atrybutów. W naszym przypadku wartością klasyfikowaną jest jakość wina.
Podczas tworzenia klasyfikatora, mamy możliwość określenia maksymalnej głębokości drzewa (max_depth) oraz ilości iteracji przycinania drzewa (m_prning).

4 Wykorzystywane technologie

Projekt został napisany w języku Python.
Do działania, wymagane są następujące biblioteki:

- SciPy
- Orange
- pygraphviz

Orange jest biblioteką wspomagającą operacje związane z eksploracją danych. Udostępnia ona narzędzie do przeprowadzania klasyfikacji, regresji, asocjacji oraz kategoryzacji. Orange pozwala na wyeksportowanie danych o drzewach w formacie .dot, które mogą zostać sparsowane przez program

graphviz. Pygraphviz jest bindingiem do graphviza i pozwala na generowanie diagramów z plików .dot.

5 Działanie programu

Na początku następuje sprawdzenie czy w systemie znajdują się wymagane moduły oraz załadowanie ich.
Następnie następuje wczytanie danych wejściowych z pliku csv do tabeli systemu Orange.
Po wczytaniu danych, następuje wygenerowanie klasyfikatora dla wczytanych danych oraz ustawionych parametrów tego klasyfikatora.
Mając wygenerowanie drzewo klasyfikujące, zapisujemy je do pliku w formacie .dot.
Wygenerowany plik .dot zostaje przetworzony przez moduł pygraphviz w celu wygenerowanie pliku graficznego PNG przedstawiającego otrzymamy klasyfikator.
W ostatnim kroku obliczamy statystyki dla naszego klasyfikatora

6 Prezentacja wyników

Wynikiem działania programu jest klasyfikator drzewiasty przedstawiony na rys 1.

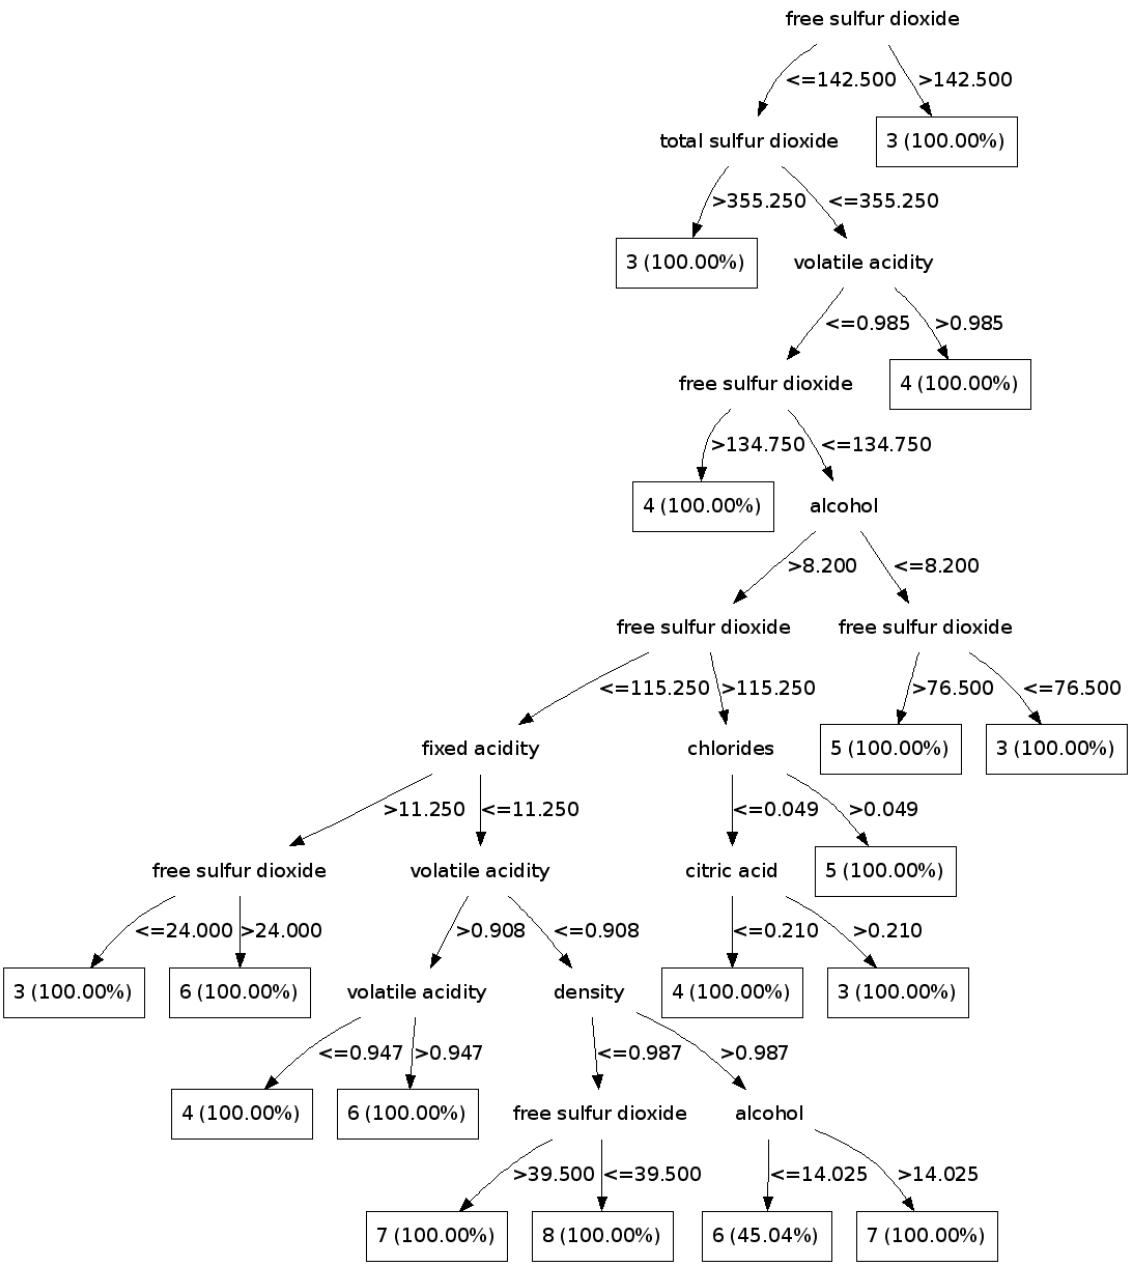

Rysunek 1: Reprezentacja graficzna klasyfikatora